

数据驱动的变速器传感器故障诊断方法

吴光强, 陶义超, 曾 翔

(同济大学 汽车学院, 上海 201804)

摘要: 针对基于模型以及基于规则的故障诊断方法的局限性, 运用数据驱动的方法对变速器传感器进行故障诊断。使用逐步回归算法建立传感器模型, 将实际传感器输出与传感器模型输出相减得到残差序列; 用小波包变换(WPT)对残差序列进行分解, 提取节点的香农熵作为特征值; 最后, 用概率神经网络(PNN)对不同传感器故障的特征值进行识别。使用硬件在环仿真获取车辆行驶过程中的变速器信号对该方法进行验证。结果表明: 该方法的诊断正确率达到98.50%, 在不同的样本划分情况下诊断正确率变化很小。此外, 还对其他多个变速器传感器进行了故障诊断, 诊断正确率均在较高值, 证明了该方法的普适性。

关键词: 变速器故障诊断; 数据驱动方法; 传感器模型; 小波包变换(WPT); 概率神经网络(PNN)

中图分类号: U461. 91

文献标志码: A

Data-driven Fault Diagnosis Method for Transmission Sensors

WU Guangqiang, TAO Yichao, ZENG Xiang

(School of Automotive Studies, Tongji University, Shanghai 201804, China)

Abstract: Aiming at the limitations of model-based and rule-based fault diagnosis methods, a data-driven fault diagnosis method for transmission sensors was proposed. First, a residual sequence was obtained between the output of actual sensor and the output of sensor model established by step-wise regression. Then, the residual sequence was decomposed by wavelet packet transform (WPT), and the Shannon entropy of each node was calculated as the feature values. Finally, a probabilistic neural network (PNN) was adopted to identify the feature values of different sensor faults. This method is verified by transmission signals from hardware-in-the-loop platform. Results indicate that the method has a diagnostic accuracy of 98.50%, and the diagnostic accuracy varies little under

different sample divisions. In addition, the fault diagnoses of two speed sensors were also performed, and the diagnostic accuracy is at a relatively high value, which proves the applicability of the method.

Key words: transmission fault diagnosis; data-driven method; sensor model; wavelet packet transform (WPT); probabilistic neural network (PNN)

安全一直是车辆领域的主题之一, 作为车辆动力传动部件的变速器对于安全驾驶有着至关重要的作用。传感器作为获取变速器信号的器件, 是变速器与控制器之间通信的重要桥梁, 传感器的正常与否直接影响变速器的性能, 所以对于传感器的故障诊断至关重要。

传感器的故障诊断方法有3种, 分别为基于模型、基于规则与数据驱动的故障诊断方法^[1-2]。

在能够获得系统精确解析模型的情况下, 基于模型的故障诊断方法是最直接有效的, 但对于变速器这样的复杂系统, 精确的解析模型一般难以获得。此外, 模型的不确定性、系统的非线性特性等都会对诊断结果产生很大影响。Lee^[3]使用奇偶方程法对电动助力转向系统中的传感器进行故障诊断, 由于模型存在不确定性, 因此设置自适应阈值来提高故障诊断的鲁棒性, 但该方法的对象是线性时不变系统, 对于变速器这样的非线性时变系统而言适用性较差。Wang等^[4]研究了多输入-多输出非线性模型的故障诊断方法, 通过将该模型转化为多个一维的线性等效模型来处理非线性问题, 简化了建模工作量, 但没有分析系统内部结构对故障诊断产生的影响, 这在模型简化时是必须要考虑的。

基于规则的故障诊断方法要求积累足够的故障原因与故障表象的先验知识, 然后将知识转化为推

收稿日期: 2020-06-11

基金项目: 国家自然科学基金(U1764259)

第一作者: 吴光强(1965—), 男, 教授, 博士生导师, 工学博士, 主要研究方向为变速器控制、整车控制、智能驾驶算法等。E-mail: wuguangqiang@tongji.edu.cn



论文
拓展
介绍

理规则。运用故障树分析(FTA)、失效模式和效果分析(FMEA)等方法实现故障诊断,优点是规则非常容易修改,缺点是知识获取困难。Yang等^[5]通过FTA方法对传感器故障进行诊断,仅考虑2种故障规则就多达102条,工作量很大。变速器系统复杂,传感器数量多,在FAT方法下故障规则可达到300多条。Zhang等^[6]运用概率分布方法对知识中的不确定性进行了处理,但是只适用于简单系统。

数据驱动的故障诊断方法不需要建立精确的解析模型,也不需要足够的先验知识,只需要通过对传感器信号的变化特性进行分析,再结合人工神经网络、主成分分析等识别算法就可完成对传感器故障的诊断。范立维^[7]和Ji等^[8]通过小波包分析、集成经验模态分解等对传感器信号进行特征值提取,再通过支持向量机算法实现对传感器故障的识别,但只考虑了传感器信号稳定时情况。Wang等^[9]不直接分析传感器信号,而是通过对传感器信号残差进行分析来实现故障诊断,动态和稳态时均有较好效果。

目前基于模型的故障诊断方法大多只针对传感器进行建模,不能从变速器系统的角度出发进行故障诊断,基于规则的故障诊断方法多见于企业,企业依靠多年的行业经验能够建立比较全面的诊断规则,数据驱动的故障诊断方法随着人工智能的兴起

逐渐成为研究热点,越来越多的学者投入其中。变速器是一个复杂的系统,由众多零部件组成,而且工况变化多端,传感器输出呈现动态性强、噪声多等特点,基于模型和基于规则的变速器传感器故障诊断方法耗时长、难度大,不能实现快速有效的故障诊断。针对以上问题,提出以小波包变换(WPT)和概率神经网络(PNN)为基础的数据驱动的变速器传感器故障诊断方法。

1 数据驱动的故障诊断方法

数据驱动的变速器传感器故障诊断方法流程如图1所示。以离合器油压传感器故障诊断为例,驾驶员通过加速踏板和制动踏板控制车辆行驶,获取车辆行驶过程中的整车及变速器数据。油压传感器的实际输出为 y ,从获取的数据中选取轮速、行驶挡位、预换挡位、输入轴转速、发动机转速、同步器位置作为油压传感器模型的输入。使用逐步回归算法建立油压传感器模型,模型的输出为 \hat{y} ,油压传感器的实际输出与模型输出相减得到油压传感器信号的残差序列 Δy ,将 Δy 通过WPT分解,计算每个节点的香农熵作为特征值,然后使用PNN对特征值的类别进行识别,从而完成故障的诊断工作。

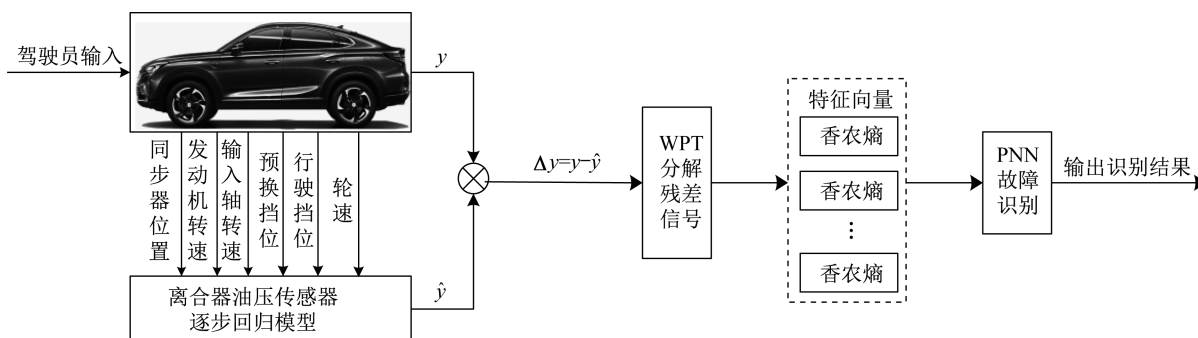


图1 数据驱动的变速器传感器故障诊断方法流程

Fig.1 Flow chart of data-driven diagnosis method for transmission sensors

1.1 逐步回归算法

逐步回归算法的基本思想是通过计算自变量对因变量贡献度的大小,逐步引入对因变量贡献显著的自变量,并剔除对因变量贡献不显著的自变量,一直重复此过程,直到所有对因变量贡献显著的自变量都被引入,所有对因变量贡献不显著的自变量都被剔除,这样就可以建立起最优的多元线性回归模型^[10]。衡量自变量对因变量贡献度的指标是偏回归平方和。假设逐步回归算法的输入样本为 $n \times$

$(m-1)$ 的矩阵, n 代表样本数, $(m-1)$ 代表自变量的个数,为统一表达,将输入与因变量组成 $n \times m$ 的矩阵 x ,最后一列代表因变量。为了消除量纲差异带来的影响,需要对输入进行标准化处理,标准化的公式如下所示:

$$x'_{i,j} = \frac{x_{i,j} - \bar{x}_j}{\sqrt{\frac{1}{m} \sum_{k=1}^m (x_{i,k} - \bar{x}_k)^2}} \quad (1)$$

式中: $x_{i,j}$ 、 $x'_{i,j}$ 分别是标准化前、后的第 i 个样本中第 j

个变量(包括自变量与因变量,下同)的值, $i=1, 2, \dots, n, j=1, 2, \dots, m; \bar{x}_i$ 是第 i 个样本的算术平均值。第 j 个变量的偏回归平方和定义为

$$p_j = \frac{r_{j,m}^2}{r_{j,j}} \quad (2)$$

式中: $r_{j,m}$ 是第 j 个自变量与因变量的相关系数; $r_{j,j}$ 是第 j 个自变量的自相关系数。相关系数描述自变量与因变量之间的相关程度, 表示为

$$r_{j,m} = \frac{\sum_{k=1}^m (x'_{k,j} - \bar{x}'_j)(x'_{k,m} - \bar{x}'_m)}{\sqrt{\sum_{k=1}^m (x'_{k,j} - \bar{x}'_j)^2} \sqrt{\sum_{k=1}^m (x'_{k,m} - \bar{x}'_m)^2}} \quad (3)$$

式中: \bar{x}'_j, \bar{x}'_m 是第 j 个自变量与因变量的平均值。计算所有变量之间的相关系数后得到相关系数矩阵

$$R = \begin{bmatrix} r_{1,1} & r_{1,2} & \cdots & r_{1,m-1} & r_{1,m} \\ r_{2,1} & r_{2,2} & \cdots & r_{2,m-1} & r_{2,m} \\ \vdots & \vdots & & \vdots & \vdots \\ r_{m-1,1} & r_{m-1,2} & \cdots & r_{m-1,m-1} & r_{m-1,m} \\ r_{m,1} & r_{m,2} & \cdots & r_{m,m-1} & r_{m,m} \end{bmatrix}$$

选择未被引入的自变量中对因变量贡献最大的自变量作为待引入的自变量, 选择已被引入的自变量中对因变量贡献最小的自变量作为待剔除的自变量, 根据 F 检验值决定待选的自变量是否被引入或剔除。 F 检验值计算式如下所示:

$$F_{in,l} = \frac{\mu_{in,l}}{r_{m,m,l-1} - \mu_{in,l}} (n-l-1) \quad (4)$$

$$F_{ex,l} = \frac{\mu_{ex,l}}{r_{m,m,l}} (n-l-1) \quad (5)$$

式中: $F_{in,l}, F_{ex,l}$ 为第 l 次重复时待引入与待剔除自变量的检验值; $\mu_{in,l}, \mu_{ex,l}$ 为第 l 次重复时待引入与待剔除自变量的偏回归平方和; $r_{m,m,l-1}, r_{m,m,l}$ 为第 $(l-1), l$ 次重复时的自相关系数。设 F_a 是 F 检验的临界值, 当 $F_{in,l} \geq F_a$ 时, 将待选自变量引入, 当 $F_{ex,l} < F_a$ 时, 将待选自变量剔除。每次完成自变量的筛选之后根据求逆变换原理进行相关系数矩阵的更新, 如下所示:

$$r_{i,j,l} = \begin{cases} r_{i,j,l-1} - r_{i,v,l-1} \frac{r_{v,j,l-1}}{r_{v,v,l-1}}, & i \neq v, j \neq v \\ \frac{r_{v,j,l-1}}{r_{v,v,l-1}}, & i = v, j \neq v \\ -\frac{r_{i,v,l-1}}{r_{v,v,l-1}}, & i \neq v, j = v \\ \frac{1}{r_{v,v,l-1}}, & i = v, j = v \end{cases} \quad (6)$$

式中: v 是待引入自变量的索引。

1.2 WPT-PNN

残差序列经过 WPT 分解之后提取香农熵作为特征值, 然后用 PNN 对特征值进行识别, 从而对故障做出诊断。WPT-PNN 结构如图 2 所示。

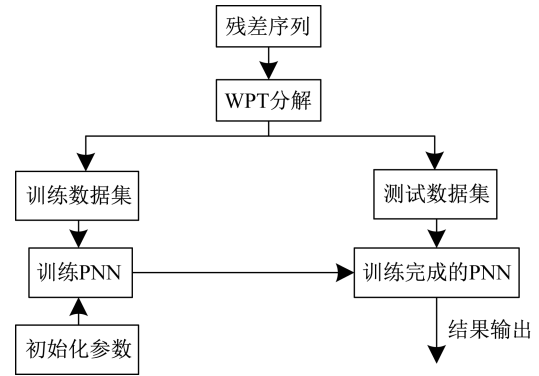


图2 WPT-PNN 结构

Fig.2 Structure of WPT-PNN

1.2.1 WPT

WPT 是在离散小波变换的基础上发展而来, 通过同时对信号的高频部分和低频部分进行分解, 确保信号的信息不会丢失。

WPT 的基本原理是将信号通过低通滤波器和高通滤波器后, 再进行下采样过程, 信号被分解为低频部分和高频部分。低频部分被称为近似系数, 高频部分被称为细节系数, 近似系数和细节系数统称为节点。将每个节点继续通过低通滤波器和高通滤波器后, 再进行下采样, 得到下一层节点, 不断重复此过程, 直至达到预定的分解层数^[11]。假设得到的残差序列 $\Delta y = (\Delta y_1, \Delta y_2, \dots, \Delta y_u)$, u 代表采样点数。分解层数为 J , 则得到 2^J 个节点, 节点的长度 $d = u/2^J$ 。近似系数和细节系数的计算式分别为

$$l_J = Ga_{J-1} \quad (7)$$

$$h_J = Ha_{J-1} \quad (8)$$

式中: l_J, h_J 分别是第 J 层的近似系数和细节系数; G, H 分别是低通滤波器和高通滤波器, 由小波函数构成; a_{J-1} 是第 $(J-1)$ 层的节点值。

Δy 经过 WPT 分解后, 提取节点的香农熵作为特征值。香农熵是度量信号不确定性大小的指标, 也是 WPT 常用的特征之一。香农熵的计算式如下所示:

$$S_J(k) = - \sum_{p=1}^d e_J(p) \ln e_J(p) \quad (9)$$

式中: $S_J(k)$ 是第 J 层第 k 个节点的香农熵, $k=1, 2, \dots, 2^J$; $e_J(p)$ 是该节点中第 p 个数据点的能量占

比。 $e_j(p)$ 的计算式如下所示:

$$e_j(p) = \frac{a_{j,k}^2(p)}{\sum_{p=1}^d a_{j,k}^2(p)} \quad (10)$$

式中: $a_{j,k}(p)$ 是第 J 层第 k 个节点中第 p 个数据点的值。由式(10)可以得到香农熵的特征向量 $\mathbf{s} = [s_1, s_2, \dots, s_{2^J}]$ 。

1.2.2 PNN

PNN以径向基神经网络(RBF)为基础,采用贝叶斯决策规则为分类依据,克服了反向传播神经网络(BPNN)局部最优问题以及RBF对径向基函数敏感问题,训练容易,收敛速度快,非常适用于实时处理^[12]。PNN的一般结构如图3所示。

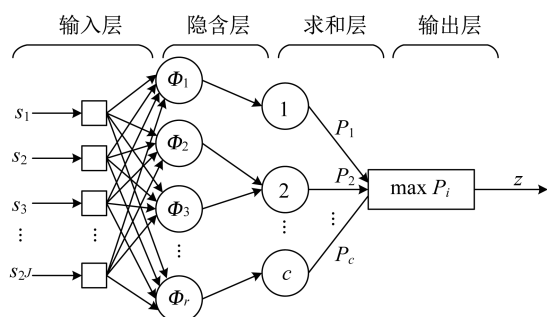


图3 PNN结构

Fig.3 Structure of PNN

PNN包含4层结构,输入层用于接收来自样本的值,神经元个数与输入向量长度相同,隐含层为径向基层,激活函数为高斯核函数。隐含层有 r 个神经元,第 q 个神经元的输出

$$\Phi_q(s) = e^{-\frac{(s - \mathbf{w}_q)(s - \mathbf{w}_q)^T}{2\sigma^2}} \quad (11)$$

式中: $\Phi_q(s)$ 是第 q 个隐含层神经元的输出, $q = 1, 2, \dots, r$; σ 是平滑因子,对网络性能起着至关重要的作用; \mathbf{w}_q 是第 q 个隐含层神经元的权重向量。求和层对隐含层的输出做加权平均,每一个求和层神经元代表一种类别。求和层共有 c 个神经元,第 b 个神经元的输出结果

$$P_b = \frac{1}{L} \sum_{q=1}^L \Phi_{b,q}(s) \quad (12)$$

式中: P_b 是第 b 个类别的加权输出, $b = 1, 2, \dots, c$,其中 c 是样本类别数; L 是指向第 b 个类别的隐含层神经元数。输出层依照贝叶斯决策规则决定输出的类别,贝叶斯决策的目的是使误判的风险降到最小。定义风险函数

$$R(c_b|\mathbf{s}) = \sum_{h=1}^c \lambda_{b,h} P(c_h|\mathbf{s}) \quad (13)$$

式中: $R(c_b|\mathbf{s})$ 是将输入向量 \mathbf{s} 判断为第 b 个类别的风险; $\lambda_{b,h}$ 是把类别 h 判断为类别 b 的损失; $P(c_h|\mathbf{s})$ 是将输入向量 \mathbf{s} 判断为类别 h 的条件概率,对应求和层中第 h 个神经元的输出。对 $\lambda_{b,h}$ 定义,分类错误的损失为1,分类正确的损失为0,则式(13)就变成 $R(c_b|\mathbf{s}) = 1 - P(c_b|\mathbf{s})$,要使 $R(c_b|\mathbf{s})$ 最小, $P(c_b|\mathbf{s})$ 最大,则输出层取最大求和层输出对应的类别,即:

$$z = \arg \max_b (R(c_b|\mathbf{s})) \quad (14)$$

2 方法验证

2.1 数据采集

为验证本方法,使用硬件在环仿真试验台进行传感器故障数据的采集。硬件在环仿真试验台由宿主机、目标机、执行器(电磁阀)、输入(制动踏板和加速踏板)、控制器等组成,如图4所示。宿主机中储存车辆模型以及变速器的控制策略,试验车辆为某款长安CS系列SUV,搭载双离合式自动变速器(DCT)。通过C语言编译器和背景调试模式(BDM)设备将宿主机中的控制策略存储到变速器控制单元(TCU)中,TCU通过数据采集与转换板卡与目标机通信,并驱动电磁阀工作。目标机包含车辆的实时运行环境(RTW),并可以实时显示运行结果,通过TCP/IP协议与宿主机通信。采样频率设为100 Hz,试验工况为30%恒定油门起步,分别在起步、升挡过程、在挡稳定行驶、降挡过程中注入故障。在过程中的随机时间点注入故障,注入故障后5 s停止数据采集。

传感器典型故障有偏差、冲击、堵塞等^[13-14],以

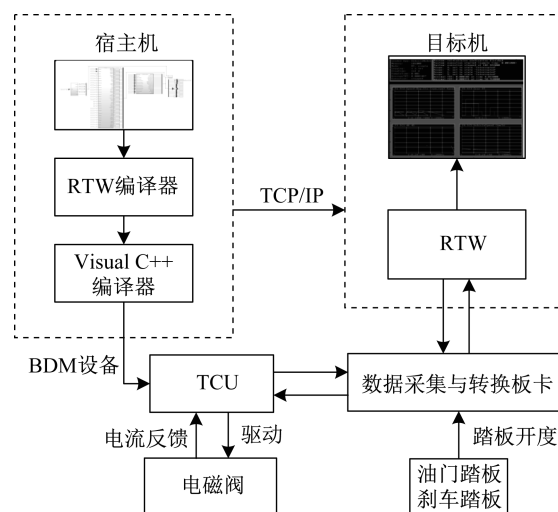


图4 硬件在环仿真试验台架构

Fig.4 Structure of hardware-in-the-loop platform

奇数离合器油压传感器为例,该传感器属于电阻应变片式传感器。图5展示了车辆稳态行驶时某些传感器典型故障的具体表现形式(1 bar=0.1 MPa)。偏差故障设置为在正常值基础上增加10%,冲击故障的冲击大小设置为最大传感器测量值,持续时间为2个采样周期,堵塞故障的恒值输出设置为故障发生前一刻的传感器测量值。每种故障采集样本80组,取发生故障前后的350个数据点作为样本点。




图5 传感器典型故障表现形式

Fig.5 Typical signal modes of sensor faults

2.2 逐步回归模型

运用第1.1节中介绍的逐步回归算法建立传感器模型。因为变速器的其他信号与目标传感器输出信号之间存在强非线性关系,而逐步回归算法属于线性回归算法,所以必须对原始的变速器信号进行处理才能使用逐步回归算法。通过取倒数、相乘、平方等方式对原始信号进行重组。根据DCT工作原理^[15],对于奇数离合器油压传感器模型,原始输入选为发动机转速、奇数输入轴转速、偶数输入轴转速、行驶挡位、预换挡位、轮速、同步器位置,重组后的输入为行驶挡位与发动机转速的乘积、发动机转速的倒数、转速的平方值等。通过逐步回归得到奇数离合器油压传感器模型,如下所示:

$$\begin{aligned} \hat{y} = & 1.06v_1 + 0.486v_2 + 28.81v_3 - 10.02v_4 + \\ & 809461v_5 - 0.07v_6 - 0.0032v_7 + 0.061v_8 - \\ & 0.12v_9 - 1.276v_{10} + 4.81v_{11} - \\ & 2.55v_{12} - 1404.85 \end{aligned} \quad (15)$$

式中: \hat{y} 为模型输出; v_1 为发动机转速; v_2 为偶数输入

轴转速; v_3 为预换挡位; v_4 为轮速; v_5 为发动机转速的倒数; v_6 和 v_7 分别为奇数输入轴转速与行驶挡位乘积及其倒数; v_8 和 v_9 分别为偶数输入轴转速与行驶挡位乘积及其倒数; v_{10} 为轮速与行驶挡位的乘积; v_{11} 为轮速与预换挡位的乘积; v_{12} 为偶数离合器油压。奇数油压传感器输出与奇数油压传感器模型输出的对比结果如图6所示。从图6可以看出,传感器模型能够较好地跟踪实际值,最大误差在0.3 bar左右,并且只出现在换挡时油压下降的过程中,其余过程均能控制在0.2 bar以下,跟踪精度达到了92%,证明了传感器模型的有效性。




图6 实际传感器输出与传感器模型输出对比

Fig.6 Comparison of actual sensor output and sensor model output

2.3 诊断结果分析

正常与故障下残差序列如图7所示。为了消除残差幅值差异带来的影响,将残差进行 $[-1,1]$ 区间的归一化处理。归一化公式如下所示:

$$\Delta y'_i = \frac{2\Delta y_i - (\max\{\Delta y_j\} + \min\{\Delta y_j\})}{\max\{\Delta y_j\} - \min\{\Delta y_j\}}, i, j = 1, 2, 3, \dots, 350 \quad (16)$$

根据第1.2节提出的方法,将从硬件在环仿真试验获得的传感器信号与传感器模型的输出相减,得到残差序列,残差序列经过WPT分解后提取香农熵作为特征值。小波函数选为离散Meyer函数,分解层数选为3层,则特征向量的维度为8,用PNN对特征向量进行识别,各层神经元个数分别为8、240、4、1。将样本进行随机划分,75%的样本用于训练,25%的样本用于测试,如表1所示。

平滑因子 σ 的大小对PNN性能有着至关重要的影响。 σ 较小时,径向基函数曲线形状较窄,只有与权值向量距离很近的输入才能获得较大输出,其他的输入对分类结果的影响很小; σ 较大时,径向基函数曲线形状较宽,与权值向量距离较远的输入也会对分类结果产生一定的影响。为了获得尽可能高的




图7 传感器正常与故障下的残差序列

Fig.7 Residual sequence of normal and faulty sensors

表1 样本划分

Tab.1 Division of samples

| 状态 | 样本总数 | 训练样本数 | 测试样本数 |
|------|------|-------|-------|
| 正常 | 80 | 60 | 20 |
| 偏差故障 | 80 | 60 | 20 |
| 冲击故障 | 80 | 60 | 20 |
| 堵塞故障 | 80 | 60 | 20 |

诊断正确率, σ 取值应适中, 既不能太大, 也不能太小。图8展示了PNN在某次训练过程中诊断正确率随 σ 变化的曲线。从图8可以看到, 诊断正确率随 σ 的增大呈现先增大后维持不变最后减小的趋势, 在 $\sigma=3\sim 16$ 时, 诊断正确率达到了最大。为了使PNN在不同的样本划分情况下仍能保持较高的诊断正确率, σ 应取大些, 本研究中的 σ 取为8。

PNN的诊断结果如图9所示, 图9同时展示了BPNN和RBF的诊断结果, 以作对比。BPNN网络层数为4层, 各层神经元个数分别为8、10、4、1; RBF网络层数为3层, 各层神经元个数分别为8、240、1。在图9的纵坐标中, 1代表正常信号, 2代表堵塞信号, 3代表偏差信号, 4代表冲击信号, 在横坐标中, 1~20样本数是正常信号, 21~40样本数是堵塞信号, 41~60样本数是偏差信号, 61~80是冲击信号。根据图9统计每种类别的诊断结果, 如表2所示。

由图9及表2可以看到, WPT-PNN 只对一个堵




图8 诊断正确率随平滑因子变化的曲线

Fig.8 Curve of diagnostic accuracy as a function of smoothing factor

塞故障识别错误, 其余均能正确识别, 而WPT-BPNN和WPT-RBF的识别错误数均大于WPT-PNN, 诊断正确率要低于WPT-PNN, 这就说明WPT-PNN的诊断性能优于其他2种方法。由于样本是随机划分为训练集和测试集, 每次划分的结果是不同的, 为了进一步探讨不同的划分结果对诊断正确率的影响, 对样本进行5次随机划分, 记录每次划分的诊断正确率。诊断正确率 α 的计算方法如下所示:

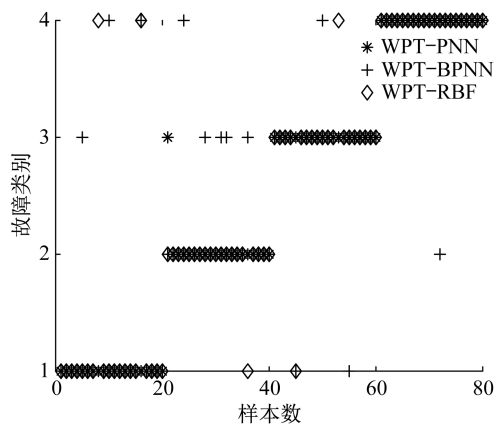


图 9 不同方法下的诊断结果对比

Fig.9 Comparison of diagnosis results between different methods


$$\alpha = \frac{1}{k} \sum_{i=1}^k (1 - (z_i - \hat{z}_i)^0) \times 100\% \quad (17)$$

式中: z_i 代表实际样本类别; \hat{z}_i 代表诊断得出的样本类别; k 为测试样本数, $k=80$ 。


表 3 不同样本划分下的诊断结果

Tab.3 Diagnostic results for different divisions of samples

| 方法 | 不同样本划分下诊断正确率/% | | | | | 平均值/% |
|----------|----------------|-------|-------|--------|-------|-------|
| | 第 1 次 | 第 2 次 | 第 3 次 | 第 4 次 | 第 5 次 | |
| WPT-PNN | 100.00 | 97.50 | 96.25 | 100.00 | 98.75 | 98.50 |
| WPT-BPNN | 85.00 | 85.00 | 82.50 | 83.75 | 78.75 | 83.00 |
| WPT-RBF | 93.75 | 87.50 | 92.50 | 88.75 | 92.50 | 91.00 |



a 奇数轴转速传感器



b 偶数轴转速传感器

图 10 转速传感器的诊断结果对比

Fig.10 Comparison of diagnosis results for speed sensors

根据图 10 统计每种类别的诊断结果,如表 4 所示。结合图 10 及表 4 可以看出,WPT-PNN 对转速传感器的诊断仍保持了较高的正确率,相比 WPT-BPNN 和 WPT-RBF,WPT-PNN 拥有较大优势,说明所采用的方法对于 DCT 中的传感器具有良好的适用性。

表 4 转速传感器的诊断结果对比

Tab.4 Comparison of diagnosis results for speed sensors

| 方法 | 各传感器诊断正确率/% | |
|----------|-------------|----------|
| | 奇数轴转速传感器 | 偶数轴转速传感器 |
| WPT-PNN | 98.75 | 97.50 |
| WPT-BPNN | 87.75 | 83.75 |
| WPT-RBF | 93.75 | 92.50 |

3 结论

(1) 采用数据驱动的方法对变速器传感器进行故障诊断,克服了基于模型以及基于规则的故障诊断方法的局限性,实现了对变速器传感器故障快速、准确的诊断。

(2) 使用逐步回归算法建立变速器传感器模型,模型输出与实际传感器输出的差值作为WPT-PNN的输入。从故障诊断与容错控制的角度出发,该模型还可在传感器故障时代替传感器,以最大限度地减小故障的影响。

(3) WPT-PNN诊断正确率高,达到98.50%,使用性能稳定,诊断正确率不会随样本的变化而产生较大波动,诊断性能优于WPT-BPNN和WPT-RBF。另外,对2个变速器输入轴转速传感器进行了故障诊断,正确率分别为98.75%和97.50%,证明了本方法对于变速器传感器的适用性。

作者贡献声明:

吴光强:指导论文方向,对论文的不足提出了建设性的意见。

陶义超:提出论文的研究思路,对论文的方法与验证部分进行了研究,撰写论文。

曾翔:利用逐步回归算法建立了传感器模型。

参考文献:

- [1] REZA S, REZA L. Isolability of faults in sensor fault diagnosis [J]. *Mechanical Systems and Signal Processing*, 2011, 25(7): 2733.
- [2] IRERMANN R. Supervision, fault-detection and fault-diagnosis methods: an introduction [J]. *Control Engineering Practice*, 1997, 5(5): 639.
- [3] LEE H. Analysis of model-based sensor fault diagnosis with application to a motor-driven power steering system [J]. *Proceedings of the Institution of Mechanical Engineering, Part D: Journal of Automobile Engineering*, 2011, 225(10): 1317.
- [4] WANG Dejun, SONG Shiyao. Robust model-based sensor fault monitoring system for nonlinear systems in sensor networks[J]. *Sensors*, 2014, 14(10): 19138.
- [5] YANG Zongxiao, YUAN Xiaobo, FENG Zhiqiang, *et al.* A fault prediction approach for process plants using fault tree analysis in sensor malfunction [C]//2006 IEEE International Conference on Mechatronics and Automation. Piscataway: IEEE, 2006:2415-2420.
- [6] ZHANG Q, OKRENT Q, APOSTOLAKIS G, *et al.* An expert system approach for fault diagnosis to cope with spurious sensor signals and process state uncertainty [J]. *Reliability Engineering & System Safety*, 1991, 34(2): 121.
- [7] 范立维. 基于DSP的自确认传感器故障诊断算法研究及优化实现[D]. 哈尔滨:哈尔滨工业大学, 2008.
- [8] FAN Liwei. Research and optimized realization of self-validating sensor fault diagnosis algorithm based on DSP [D]. Harbin: Harbin Institute of Technology, 2008.
- [9] JI Junjie, QU Jianfeng, CHAI Yi, *et al.* An algorithm for sensor fault diagnosis with EEMD-SVM [J]. *Transactions of the Institute of Measurement and Control*, 2018, 40(6): 1746.
- [10] WANG Kai, CHEN Junhui, SONG Zhihuan. Data-driven sensor fault diagnosis systems for linear feedback control loop [J]. *Journal of Process Control*, 2017, 45: 152.
- [11] 游士兵, 严研. 逐步回归分析法及其应用[J]. *统计与决策*, 2017(14):31.
- [12] YOU Shibing, YAN Yan. Stepwise regression analysis and its application[J]. *Statistics & Decision*, 2017(14):31.
- [13] WONG K M, WU J, DAVIDSON N T, *et al.* Wavelet packet division multiplexing and wavelet packet design under timing error effects [J]. *IEEE Transactions on Signal Processing*, 1997, 45(12):2877.
- [14] DUDA O R, HART E P, STORK G D. Pattern classification [M]. 2nd ed. New York: Wiley-Interscience, 2009.
- [15] BALABAN E, SAXENA A, BANSAL P, *et al.* Modeling, detection, and disambiguation of sensor faults for aerospace applications [J]. *IEEE Sensors Journal*, 2009, 9(12): 1907.
- [16] ZHANG Jianqu, YAN Yong. A wavelet-based approach to abrupt fault detection and diagnosis of sensors [J]. *IEEE Transactions on Instrumentation and Measurement*, 2001, 50(5): 1389.
- [17] 吴光强, 杨伟斌, 秦大同. 双离合器式自动变速器控制系统的关键技术[J]. *机械工程学报*, 2007, 43(2): 13.
- [18] WU Guangqiang, YANG Weibin, QIN Datong. Key technique of dual clutch transmission control system [J]. *Chinese Journal of Mechanical Engineering*, 2007, 43(2): 13.